1. Билет №1

Управление внешними устройствами: специальные файлы устройств, адресация внешних устройств и их идентификация в системе, тип dev_t. Система прерываний: типы прерываний и их особенности. Прерывания в последовательности ввода-вывода — обслуживание запроса процесса на ввод-вывод (диаграмма). Быстрые и медленные прерывания. Обработчики аппаратных прерываний: регистрация в системе — функция и ее параметры, примеры. Тасклеты — объявление, планирование (пример лаб. раб).

1.1. Специальные файлы устройств

Специальные файлы устройств обеспечивают унифицированный доступ к периферийным (внешним) устройствам. Устройства, как и всё в UNIX, представлены файлами, что обеспечивает доступ к устройствам, как к обычным файлам — можно открывать/закрывать/читать/писать. В отличие от обычных файлов, специальные файлы устройств в действительности являются только указателями на соответствующие драйверы устройств в ядре.

> *Драйвер устройства — программа, управляющая работой внешнего устройства со стороны системы.*

Файлы устройств связывают файловую систему с драйверами устройств. Каждому устройству соответствует хотя бы 1 специальный файл. Обычно они лежат в /dev корневой ФС. Подкаталоги /dev/fd содержат файлы с именами 0, 1, 2 (в некоторых системах stdio, stdout, stderr...). Со всеми устройствами система работает одинаково.

Использование СФУ для работы с аппаратной частью:

Если процесс пользователя открывает для чтения обычный файл, то системные вызовы open и read обрабатываются встроенными в ядро функциями open и read соответственно. Если файл является специальным, то будут вызваны подпрограммы open и read, определенные в соответствующем драйвере устройства.

После того, как по inode ФС распознает, что данный файл является специальным, ядро использует старший номер специального файла как индекс в конфигурационной таблице драйверов устройств. Элементом таблицы является структура, элементы которой содержат указатели на функции соответствующего драйвера. Младший номер передается драйверу, поддерживающему несколько устройств, как дополнительный параметр, указывающий конкретное устройство.

Имеется 2 типа файлов устройств:

1. Символьные — небуферизуемые (non-buffered).
2. Блочные — буферизуемые (устройства вторичной памяти).

Связь имени специального файла с конкретным внешним устройством обеспечивает inode: есть поле dev_t i_rdev.

Тип специального файла задает поле mode. Для специального блок-ориентированного файла в этом поле устанавливается маска 06000, для байт-ориентированного 020000.

На структуры, описывающие устройства, ссылается inode:

```
1  struct inode {
2      ...
3      union {
4          ...
5          struct block_device     *i_bdev;
6          struct cdev         *i_cdev;
7          ...
8      };
9      ...
10 } __randomize_layout;
```

Таким образом, структуры block_device (для блочных устройств) и cdev (для символьных устройств) определены в файловой системе Linux.

```
1  struct cdev {
2      ...
3      struct module *owner;
4      const struct file_operations *ops;
5      struct list_head list;
6      dev_t dev;
7      ...
8  } __randomize_layout;
```

Символьные устройства для регистрации в системе (нужных операций) используют структуру file_operations. При создании символьного устройства в данной структуре нужно заполнить только два поля: ops и owner (обязательное значение - THIS_MODULE).

```
1  struct block_device {
2      dev_t              bd_dev;
3      ...
4      struct inode *         bd_inode;
5      struct super_block *     bd_super;
6      ...
7      struct gendisk *     bd_disk; // (определяет устройство (специ
           ализированный интерфейс), ссылается на struct
           block_device_operations)
8      ...
9  } __randomize_layout;
```

Чтобы сделать блочные устройства доступными для ядра, драйверы блочных устройств регистрируются в ядре с помощью функции register_blkdev, но с версии 2.6.0 этот вызов необязателен и нужен только для динамического выделения старшего номера и создания записи в /proc/devices.

1.2. Адресация внешних устройств и их идентификация в системе, тип dev_t

Устройство — специальный файл, не можем идентифицировать его как обычный файл. В ядре используется тип dev_t (<linux/types.h>) для того, чтобы определять (содержать)

номера устройств. С версии 2.6.0 dev_t 32-разрядный. Представляет число, в котором 12 бит — для старшего номера, 20 — для младшего. POSIX.1 определяет существование типа, но не его формат.

Пример: жёсткий диск — устройство. Дисковое адресное пространство поделено на разделы (используются для монтирования ФС). Диск будет иметь старший номер (major id) — идентификатор класса устройства, а его разделы — младший номер (minor id).

Код пользователя не должен делать предположений о внутренней организации номера устройства, а должен просто использовать набор макросов <linux/kdev_t.h>, используемых для получения старшего и младшего номеров устройства.

```
1  MAJOR(dev_t dev);
2  MINOR(dev_t dev);
```

Для преобразования в dev_t по старшему и младшему номерам используется макрос:

```
1  MKDEV(int major, int minor);
```

До версии 2.6.0 количество номеров было ограничено: до 255 младших и до 255 старших. Позже ограничения были сняты.

Файлы устройств одного типа имеют одинаковые старшие номера и различаются по номеру, который добавляется в конец имени.

Пример: все файлы сетевых плат имеют номера Ethernet: eth0, eth1...

Если внутри /dev вызвать ls -l, увидим два числа через запятую — старший и младший номера устройств. Если выполнить cat /proc/devices — увидим старшие номера устройств, известные ядру.

1.3. Выделение/освобождение номеров устройств

Одно из первых действий, которое должен сделать драйвер при установке, например, символьного устройства, — получение 1 или более номеров устройств для работы с ними.

Для выделения символьного устройства нужно вызвать функцию

```
1  int register_chrdev_region(dev_t first, unsigned int count, char* name);
```

first — начальный номер диапазона устройств, которые мы хотим выделить (minor). К нему нет требований.

count — количество запрашиваемых номеров устройств. Если count > запрашиваемого диапазона, то может перейти на следующий старший номер. Все будет работать до тех пор, пока запрашиваемый диапазон доступен.

name — имя номера устройства, связанного с диапазоном. Можно увидеть в /proc/devices и sysfs.

Возвращает 0, если успех, отрицательное число, если ошибка.

Функция эффективна, если заранее известно конкретное устройство, которому нужен номер. Но часто неизвестно, какой старший номер использует конкретное устройство.

Есть тенденция по переходу на использование динамически разделяемых номеров устройств:

```
1  int alloc_chrdev_region(dev_t* dev, unsigned int first_minor, unsigned
       int count, char* name);
```

dev — только выходной параметр, содержит первый номер в выделенном диапазоне при успехе. firstminor — первый младший номер (нужен для идентификации устройства).

Для освобождения используется:

```
1  int unregister_chrdev_region(dev_t first, unsigned int count);
```

1.4. Статическое выделение номеров устройств

Некоторые старшие номера назначаются большинству обычных устройств статически (см. Documentation/devices.txt).

Старший номер	Тип устройства
1	Оперативная память
2	Дисковод floppy
3	1-ый контроллер жёстких IDE-дисков
4	Терминалы
5	Терминалы
6	Принтеры (параллельный код)
8	Жёсткие SCSI-диски
13	Мышь
14	Звуковые карты
22	2-ой контроллер жёстких IDE-дисков

1.5. Система прерываний: типы прерываний и их особенности

Система прерываний включает в себя:

1. Системные вызовы (синхронные — возникают в процессе выполнения программы, вызываются соответствующей командой).

2. Исключения (синхронные — возникают в процессе выполнения программы, переполнение стека/деление на 0...).

3. Аппаратные прерывания (асинхронные — не зависят ни от каких действий в системе, выполняются на высоких уровнях приоритетов, их выполнение нельзя прервать, задача — информирование процессов о событиях в системе, от системного таймера/клавиатуры..., виды: от системного таймера (единственное периодическое), от действий оператора (ктрл+с), от внешних устройств).

Про таблицы прерываний:

В 16-разрядной ОС (DOS) существует таблица векторов прерываний — таблица, содержащая векторы прерывания (far-адреса обработчиков прерывания — сегмент (2б) + смещение (2б)). Она начинается с нулевого адреса, занимает 1 Мб. Вектор прерывания - смещение в этой таблице.

В 32-разрядной ОС существует IDT (Interrupt Descriptor Table), нужная для получения адресов обработчиков прерываний, содержащая 8-байтовые дескрипторы прерываний, хранящие информацию о смещении к обработчику прерывания в соответствующем сегменте.

В 64-разрядной ОС существует IDT и список прерываний — запутанная система.

В современных системах часть перываний относится к APIC, а часть к подсистеме ОС MSI (Message Signal Interrupts).

1.6. Прерывания в последовательности ввода-вывода — обслуживание запроса процесса на ввод-вывод

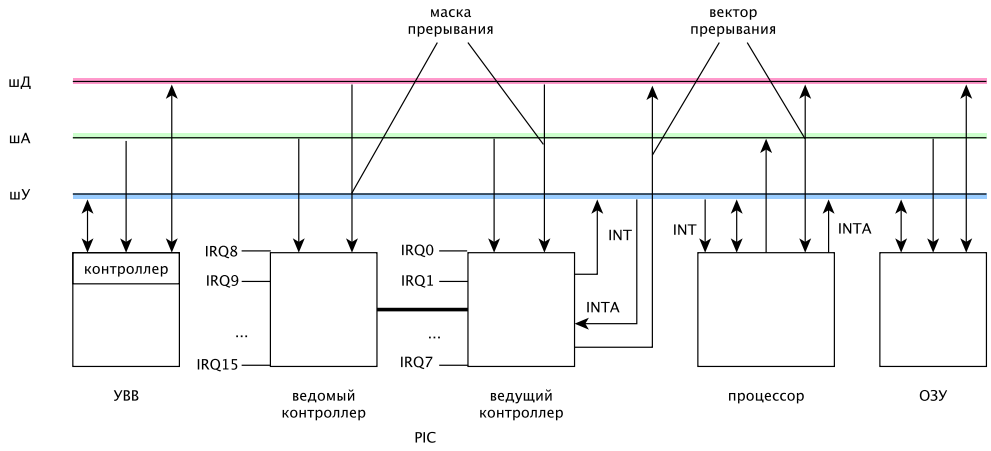

Взаимодействие компьютера с внешними устройствами выполняется с помощью аппаратных прерываний — идея распараллеливания действий, когда управление внешним устройством берёт на себя контроллер устройства (замена опроса готовности ВУ).

1. Запрос приложения на ввод/вывод переводит систему в режим ядра.
2. Подсистема ввода/вывода вызывает драйвер устройства (в драйвере есть 1 обработчик прерывания от данного устройства).
3. По окончании операции ввода/вывода контроллер устройства формирует сигнал прерывания, приходящий на соответствующую линию прерывания контроллера прерываний.
4. Контроллер формирует сигнал INT, который по ШУ идёт на выделенную ножку процессора.
5. В конце цикла выполнения каждой команды (выборка-дешифрирование-выполнение) процессор проверяет наличие сигнала на ножке. Если есть сигнал, процессор выставляет на ШУ INTA.
6. Контроллер отправляет по ШД вектор прерывания в регистры процессора.
7. Процессор смещается относительно нулевого адреса и находит в таблице адрес обработчика.

8. Процессор по шине данных отправляет в контроллер маску прерываний, ~~и контроллер адресуется по шине адреса~~.

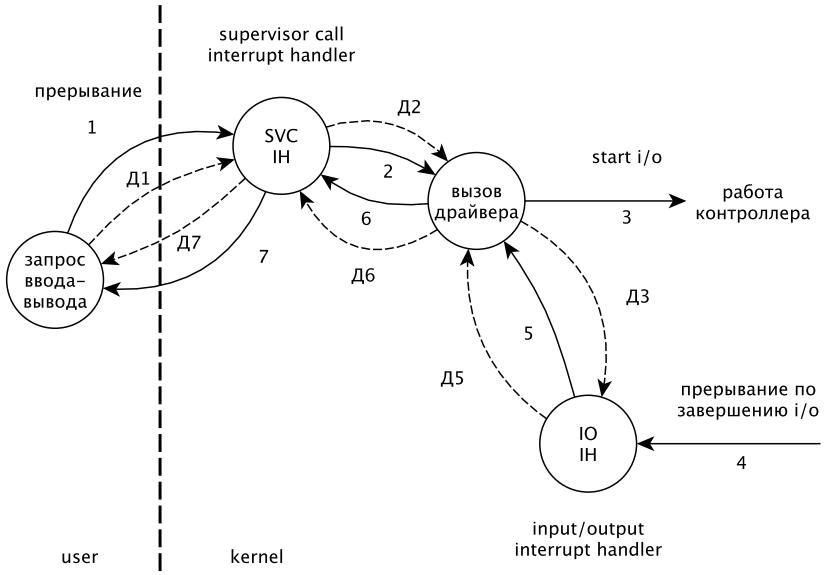

Прерывания, в зависимости от возможности запрета, делятся на:

МаскИруемые — прерывания, которые можно запрещать установкой соответствующего флага (‘IF‘ - Interruption Flag). Если он сброшен, то обработка прерываний запрещена. Если он установлен, то прерывания будут обрабатываться. Здесь речь идёт об аппаратных прерываниях, потому что программные запрещать нет смысла.

НемаскИруемые (англ. Non-maskable interrupt, NMI) — обрабатываются всегда, независимо от запретов на другие прерывания

1.7. Быстрые и медленные прерывания

Выделяются быстрые и медленные аппаратные прерывания. Быстрые — выполняются атомарно, не делятся на части, в современных системах это только прерывание от системного таймера. Медленные — все остальные, делятся на 2 части.

Любые АП выполняются на самом высоком уровне приоритета (самый высокий — системный таймер, выше него только migration для перебалансировки нагрузки между процессорами и power при падении напряжения — система отключается от питания и не может работать).

Аппаратные прерывания — важнейшие в системе, поэтому, чтобы исключить в многопроцессорных системах ошибки обработки данных, поступающих от внешних устройств, на том ядре, на котором обрабатывается прерывание, запрещаются все остальные прерывания, а в системе запрещаются все прерывания по данной линии IRQ. Никакая другая работа на данном процессоре выполняться не может, что негативно сказывается на **производительности и отзывчивости системы**, поэтому АП не могут выполняться длительное время. Поэтому работа, которую выполняют обработчики прерываний, делится на 2 части.

Эти 2 части — top_half и bottom_half. top_half (interrupt handler) копирует данные устройства в специальный буфер, инициализирует отложенное действие bottom_half (softirq, tasklet или workqueue) и завершается. top_half должен выполниться быстро, так как при этом игнорируются остальные прерывания. bottom_half выполняется при разрешённых остальных прерываниях и делает всю остальную обработку прерывания.

1.8. Обработчики аппаратных прерываний: регистрация в системе — функция и ее параметры, примеры

Основная задача обработчика прерывания — передача данных от устройства по шине данных, если была запрошена операция чтения. Даже если была запрошена операция записи, устройство все равно оправляет по шине данных информацию об успешности операции. Чтобы обработать ее, обработчик должен сохранять информацию, поступающую от устройства в буфер ядра. Затем эта информация поступит приложению, запросившему ввод/вывод.

Системная функция для регистрации обработчика прерывания:

```
1  typedef irqreturn_t (*irq_handler_t)(int, void *);
2
3  int request_irq(unsigned int irq, irq_handler_t handler, unsigned long
       flags, const char* name, void *dev);
```

irq — номер линии прерывания. handler — обработчик прерывания. flags — флаги. name — имя обработчика. dev - указатель на некоторый объект, используется для освобождения линии прерывания от указанного обработчика:

```
1  const void *free_irq(unsigned int irq, void *dev_id);
```

Пример:

```
1  rc = request_irq(IRQ_NUMBER, interrupt_handler, IRQF_SHARED, "
       tasklet_interrupt_handler", interrupt_handler);
```

Флаг IRQF_SHARED указывает, что данная линия прерывания может быть разделена несколькими обработчиками. IRQF_TIMER — флаг, маскирующий данное прерывание как прерывание от таймера. IRQF_PROBE_SHARED — устанавливается абонентами, если возможны проблемы при совместном использовании линии.

1.9. Тасклеты — объявление, планирование

Тасклет — специальный тип softirq. Тасклеты представлены двумя типами отложенных прерываний: HI_SOFTIRQ (вып. раньше) и TASKLET_SOFTIRQ.

Тасклет не может выполняться параллельно, выполняется атомарно на том же процессоре, на котором выполняется обработчик запланировавшего его прерывания. Инициализируется как статически, так и динамически. Выполняется в контексте прерывания — нельзя использовать средства взаимоисключения, кроме spinlocks (активное ожидание на процессоре). Выполняется ksofirqd. Является упрощённым интерфейсом softirq.

Определена структура:

```
1  struct tasklet_struct
2  {
3    struct tasklet_struct *next; // указатель на следующий тасклет в односвя
       зном списке
4    unsigned long state; // состояние тасклета
5    atomic_t count; // счетчик ссылок
6    bool use_callback; // флаг
7    union {
8      void (*func)(unsigned long data); // функция-обработчик тасклета
9      void (*callback)(struct tasklet_struct *t);
10   };
11   unsigned long data; // аргумент функции-обработчика тасклет
12 };
```

Тасклеты в отличие от softirq могут быть зарегистрированы как статически, так и динамически. Статически тасклеты создаются с помощью двух макросов (man 6.2.1):

```
1  #define DECLARE_TASKLET(name, _callback)      \
2  struct tasklet_struct name = {          \
```

```
3     .count = ATOMIC_INIT(0),        \
4     .callback = _callback,          \
5     .use_callback = true,           \
6 }
7 #define DECLARE_TASKLET_DISABLED(name, _callback) \
8 struct tasklet_struct name = {          \
9     .count = ATOMIC_INIT(1),        \
10    .callback = _callback,          \
11    .use_callback = true,           \
12 }
```

Оба макроса статически создают экземпляр структуры struct tasklet_struct с указанным именем (name). Например,

```
1 DECLARE_TASKLET(my_tasklet, tasklet_handler);
```

Эта строка эквивалентна следующему объявлению:

```
1 struct tasklet_struct my_tasklet = {NULL, 0, ATOMIC_INIT(0),
      tasklet_handler};
```

В данном примере создается тасклет с именем my_tasklet, который разрешен для выполнения. Функция tasklet_handler будет обработчиком этого тасклета. Поле dev отсутствует в текущих ядрах.

При динамическом создании тасклета объявляется указатель на struct tasklet_struct, а затем для инициализации вызывается функция:

```
1 extern void tasklet_init(struct tasklet_struct *t, void (*func)(unsigned
      long), unsigned long data);
```

Пример:

```
1 tasklet_init(t, tasklet_handler, data);
```

Тасклеты должны быть зарегестрированы для выполнения. Тасклеты могут быть запланированы на выполнение функциями:

```
1 tasklet_schedule(struct tasklet_struct *t);
2 tasklet_hi_shedule(struct tasklet_struct *t);
```

Когда тасклет запланирован, ему выставляется состояние TASKLET_STATE_SCHED, и он добавляется в очередь. Пока он находится в этом состоянии, запланировать его еще раз

не получится, т.е. в этом случае просто ничего не произойдет. Тасклет не может находиться сразу в нескольких местах очереди на планирование, которая организуется через поле next структуры tasklet_struct. После того, как тасклет был запланирован, он выполниться только один раз.

Свойства:

1. Если вызывается функция tasklet_schedule(), то после этого тасклет гарантированно будет выполнен на каком-либо процессоре хотя бы один раз.

2. Если тасклет уже запланирован, но его выполнение все еще не запущено, он будет выполнен только один раз.

3. Если этот тасклет уже запущен на другом процессоре (или schedule вызывается из самого тасклета), выполнение переносится на более поздний срок.

4. Если разработчик считает, что в данном тасклете нужно выполнить действия, которые могут выполняться в других таскоетах, он реализует взаимоисключение с помощью spinlocks.

Критерии	softirq	tasklet	workqueue
Определение	10 шт. определено в ядре статически	С + Д	С + Д
Взаимоискл.	Да	Нет	Да
Возможность паралл. вып.	Да	Нет	Да
Выполнение	В контексте спец. потоков ядра (ksoftirqd)	В контексте запланировавшего обраб. прерыв.	В контексте спец. потоков ядра (kworker)
Блокируются	Наверное нет	Нет	Да

1.10. spin_lock

Race condition — условия гонок: процессы выполняются с разной скоростью и пытаются получить доступ к разделяемым переменным.

Аппаратная реализация взаимоисключения — test_and_set. Атомарная функция, реализующая как неделимое действие проверку и установку значения в памяти. По сути,

читает значение переменной b, копирует его в a, устанавливает b значение true. Считается, что это не приведет к бесконечному откладыванию.

Использование test_and_set в цикле проверки значения переменной называется циклической блокировкой. Spin-блокировки — активное ожидание на процессоре (время непроизводительно расходуется на проверку флага другого процессора). Реализация test_and_set связана с блокировкой локальной шины памяти, в результате один поток может занять шину на длительное время, что понижает отзывчивость (решение — 2 вложенных цикла, если переменная занята — выполняется обычный цикл без блокировки шины).

```
1  void spin_lock(spin_lock_t* c)
2  {
3    while (test_and_set(*c) != 0)
4    {
5      /* ресурс занят */
6
7      /*
8      while (*c != 0)
9      {
10     ...
11     }
12     */
13   }
14 }
15
16 void spin_unlock(spin_lock_t* c)
17 {
18   *c = 0;
19 }
```

Циклическую блокировку может удерживать только 1 поток. Захваченная — в состоянии contended. Если другой поток пытается захватить уже захваченную, то блокировка находится в состоянии конфликта, а поток выполняет цикл проверки busy_loop. Блокировка должна быть связана с тем, что она блокирует. Запрещаются данные (разделяемый ресурс), а не код. В этой блокировке есть смысл, только когда ее длительность не превышает 2 переключений контекста.

Пример из лабораторной:

```
1 #include <linux/kernel.h>
2 #include <linux/module.h>
3 #include <linux/interrupt.h>
```

```
4  #include <linux/slab.h>
5  #include <asm/io.h>
6
7  #include "ascii.h"
8
9  #define IRQ_NUMBER 1
10
11 MODULE_LICENSE("GPL");
12 MODULE_AUTHOR("Karpova Ekaterina");
13
14 struct tasklet_struct *tasklet;
15 char tasklet_data[] = "key pressed";
16
17 void tasklet_func(unsigned long data)
18 {
19     printk(KERN_INFO "+: ----------");
20     printk(KERN_INFO "+: tasklet began");
21     printk(KERN_INFO "+: tasklet count = %u", tasklet->count.counter);
22     printk(KERN_INFO "+: tasklet state = %lu", tasklet->state);
23
24     printk(KERN_INFO "+: key code - %d", data);
25     if (data < ASCII_LEN)
26         printk(KERN_INFO "+: key press - %s", ascii[data]);
27     if (data > 128 && data < 128 + ASCII_LEN)
28         printk(KERN_INFO "+: key release - %s", ascii[data - 128]);
29
30     printk(KERN_INFO "+: tasklet ended");
31     printk(KERN_INFO "+: ----------");
32 }
33
34 static irqreturn_t my_irq_handler(int irq, void *dev_id)
35 {
36   int code;
37   printk(KERN_INFO "+: my_irq_handler called\n");
38
39   if (irq != IRQ_NUMBER)
40   {
41     printk(KERN_INFO "+: irq not handled");
```

```
42      return IRQ_NONE;
43    }
44
45    printk(KERN_INFO "+: tasklet state (before schedule) = %lu",
46                     tasklet->state);
47    code = inb(0x60);
48    tasklet->data = code;
49    tasklet_schedule(tasklet);
50    printk(KERN_INFO "+: tasklet scheduled");
51    printk(KERN_INFO "+: tasklet state (after schedule) = %lu",
52                      tasklet->state);
53
54    return IRQ_HANDLED;
55  }
56
57  static int __init my_init(void)
58  {
59    if (request_irq(IRQ_NUMBER, my_irq_handler, IRQF_SHARED, "
          tasklet_irq_handler", (void *) my_irq_handler))
60    {
61      printk(KERN_ERR "+: cannot register irq handler\n");
62      return -1;
63    }
64
65    tasklet = kmalloc(sizeof(struct tasklet_struct), GFP_KERNEL);
66
67    if (tasklet == NULL)
68    {
69          printk(KERN_ERR "+: kmalloc error");
70          return -1;
71    }
72
73    tasklet_init(tasklet, tasklet_func, (unsigned long)tasklet_data);
74
75    printk(KERN_INFO "+: module loaded\n");
76    return 0;
77  }
78
```

```
79 static void __exit my_exit(void)
80 {
81    tasklet_kill(tasklet);
82    free_irq(IRQ_NUMBER, my_irq_handler);
83 
84    printk(KERN_INFO "+: module unloaded\n");
85 }
86 
87 module_init(my_init);
88 module_exit(my_exit);
```

1.11. Очереди работ — объявление, создание, постановка работы в очередь, планирование

Очереди работ — еще один тип bottom_half (отложенного действия). Кроме очередей, которые мы создаём, есть общесистемные очереди и соответствующие возможности для работы с этими очередями. Определена структура в <linux/workqueue.h>.

```
1    struct workqueue_struct {
2    struct list_head  pwqs;    /* WR: all pwqs of this wq */
3    struct list_head  list;    /* PR: list of all workqueues */
4 
5    struct mutex     mutex;     /* protects this wq */
6    int       work_color; /* WQ: current work color */
7    int       flush_color;  /* WQ: current flush color */
8    atomic_t     nr_pwqs_to_flush; /* flush in progress */
9    struct wq_flusher *first_flusher; /* WQ: first flusher */
10   struct list_head  flusher_queue;  /* WQ: flush waiters */
11   struct list_head  flusher_overflow; /* WQ: flush overflow list */
12 
13   struct list_head  maydays;  /* MD: pwqs requesting rescue */
14   struct worker    *rescuer; /* MD: rescue worker */
15 
16   int       nr_drainers;  /* WQ: drain in progress */
17   int       saved_max_active; /* WQ: saved pwq max_active */
18 
19   struct workqueue_attrs  *unbound_attrs; /* PW: only for unbound wqs */
20   struct pool_workqueue *dfl_pwq; /* PW: only for unbound wqs */
```

```
21
22 #ifdef CONFIG_SYSFS
23   struct wq_device  *wq_dev;  /* I: for sysfs interface */
24 #endif
25 #ifdef CONFIG_LOCKDEP
26   char       *lock_name;
27   struct lock_class_key key;
28   struct lockdep_map  lockdep_map;
29 #endif
30   char       name[WQ_NAME_LEN]; /* I: workqueue name */
31
32   /*
33    * Destruction of workqueue_struct is RCU protected to allow walking
34    * the workqueues list without grabbing wq_pool_mutex.
35    * This is used to dump all workqueues from sysrq.
36    */
37   struct rcu_head   rcu;
38
39   /* hot fields used during command issue, aligned to cacheline */
40   unsigned int     flags ____cacheline_aligned; /* WQ: WQ_* flags */
41   struct pool_workqueue __percpu *cpu_pwqs; /* I: per-cpu pwqs */
42   struct pool_workqueue __rcu *numa_pwq_tbl[]; /* PWR: unbound pwqs
       indexed by node */
43 };
```

На процессор имеется 2 kworker: normal и high. Это соответствует созданию очередей с нормальным и высоким уровнем приоритета, вторые будут выполняться раньше, но это разные воркеры.

worker — рабочий поток ядра (worker_thread).

Все воркеры выполняются как обычные потоки ядра, при этом они выполняют функцию worker_thread().

1. После инициализации worker_thread() она входит в бесконечный цикл и засыпает (прерываемый сон).

2. Она просыпается, когда в очередь ставится какая-то работа и начинает выполнять ее.

3. Закончив выполнение работы, поток опять засыпает.

В системе также есть структура

```
/*
* Очередь отложенных действий, связанная с процессором:
*/
struct cpu_workqueue_struct
{
    spinlock_t lock; /* Очередь для защиты данной структуры */
    long remove_sequence; /* последний добавленный элемент
   (следующий для запуска ) */
    long insert_sequence; /* следующий элемент для добавления */
    struct list_head worklist; /* список действий на каждое cpu */
    wait_queue_head_t more_work;
    wait_queue_head_t work_done;
   struct workqueue_struct *wq; /* соответствующая структура
                                   workqueue_struct */
     task_t *thread; /* соответствующий поток (функция) */
     int run_depth; /* глубина рекурсии функции run_workqueue() */
};
```

Иллюстрация для cpu0 (для всех cpu одинаково):

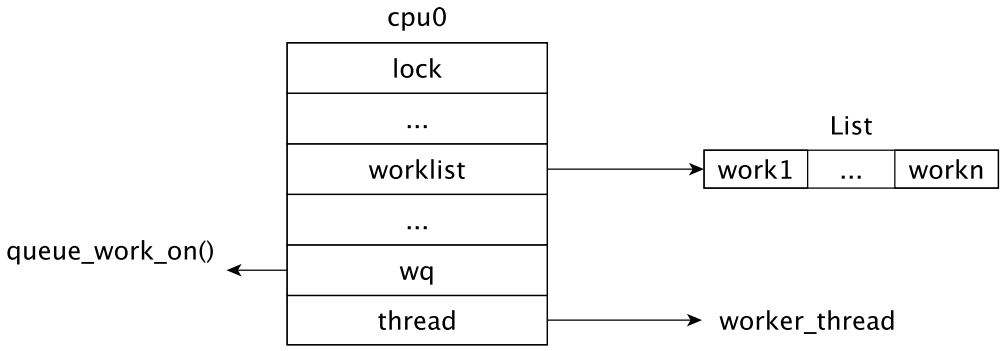

wq — указатель на инициализированную структуру очереди работ.

Работа описывается структурой (1 экземпляр на каждое отложенное действие):

```
typedef void (*work_func_t) (struct work_struct *work);
  struct work_struct {
        atomic_long_t data;
        struct list_head entry;
        work_func_t func; // обработчик работы
#ifdef CONFIG_LOCKDEP
```

```
7           struct lockdep_map lockdep_map;
8   #endif
9   };
```

В современных системах очередь работ создается функцией alloc_workqueue():

```
1   struct workqueue_struct *alloc_workqueue(const char *fmt,
2               unsigned int flags,
3               int max_active, ...);
```

fmt - формат на имя очереди (workqueue), но в отличие от старых реализаций потоков с этим именем не создается. flags - флаги определяют как очередь работ будет выполняться. max_active - ограничивает число задач (work) из некоторой очереди, которые могут выполняться одновременно на любом CPU.

Кроме этой, есть еще функция:

```
1   #define alloc_ordered_workqueue(fmt, flags, args...)        \
2   alloc_workqueue(fmt, WQ_UNBOUND | __WQ_ORDERED |      \
3       __WQ_ORDERED_EXPLICIT | (flags), 1, ##args)
```

create_workqueue() — устаревшая.

Несколько объектов, связанных с очередью работ (workqueue), представлены в ядре соответствующими структурами:

1. Работа (work);
2. Очередь работ (workqueue) – коллекция work. Workqueue и work относятся как один-ко-многим;
3. Рабочий (worker). Worker соответствует потоку ядра worker_thread;
4. Пул рабочих потоков (worker_pool) это – набор рабочих (worker). Worker_pool и worker относятся как «один ко многим»;
5. Pwd (pool_workqueue) это – посредник, который отвечает за отношение workqueue и worker_pool: workqueue и pwd является отношением один-ко-многим, а pwd и worker_pool – отношение один-к-одному.

   Для начала пулы для привязанных очередей (на картинке). Для каждого CPU статически выделяются два worker pool: один для высокоприоритетных work'ов, другой — для work'ов с нормальным приоритетом. То есть, если ядра у нас четыре, то привязанных пулов будет всего восемь, не смотря на то, что workqueue может быть сколько угодно.

Когда мы создаем workqueue, у него для каждого CPU выделяется служебный pool_workqueue (pwq). Каждый такой pool_workqueue ассоциирован с worker pool, который выделен на том же CPU и соответствует по приоритету типу очереди. Через них workqueue взаимодействует с worker pool.

Worker'ы исполняют work'и из worker pool без разбора, не различая, к какому workqueue они принадлежали изначально.

Для непривязанных очередей worker pool'ы выделяются динамически.

1.12. Флаги

1. WQ_UNBOUND — очередь работ не связана ни с каким cpu.
2. WQ_FREEZABLE — очередь работ может блокироваться.
3. WQ_HIGHPRI — задания, представленные в такую очередь, будут поставлены в начало очереди и будут выполняться (почти) немедленно.
4. WQ_CPU_INTENSIVE — очередь работ может интенсивно использовать процессор.
5. WQ_POWER_EFFICIENT — очереди работ, связанные с конкретным процессором, являются более предпочтительными, так как имеют более высокую производительность благодаря локальному кешу. Но такая привязанность к конкретному процессору имеет отрицательный побочный эффект — увеличение энергопотребления.

Продолжение про WQ_POWER_EFFICIENT

Это связано с тем, что если энергия не тратится, процессор простаивает.

Такие соображения учитываются в любой системе.

Таким образом, если нет workqueue, привязанных к конкретному процессору, можно «не трогать» этот неработающий процессор и, если позволяют соответствующие условия, выполнять эту работу на том процессоре, который работает.

Фактически мы можем ограничиться одним процессором...

1.13. Создание работы

Мы создаем очередь работ для того, чтобы поместить в нее нужные нам действия (работы).

Существует статический способ определения работы с помощью макроса

Листинг 1..1: Статический способ определения

```
1 DECLARE_WORK(name, void (*func)(void*));
2 struct work_struct *name; // имя (экземпляра) структуры work_struct
```

func – имя функции, которая вызывается из workqueue (код для выполнения отложенных действий, нижняя половина).

Работу можно определить динамически т.е. в процессе выполнения программы:

Листинг 1..2: Динамический способ определения

```
1 #define INIT_WORK(_work, func) __INIT_WORK((_work,(func), 0)
```

Листинг 1..3: Определение __INIT_WORK()

```
1 __INIT_WORK((_work, _func, _onstack)
2 do {
3       ...
4       INIT_LIST_HEAD(&(work)->entry);
5       (_work)->func=(-func);
6 } while (0);
```

Также может встретиться функция PREPARE_WORK(). INIT_WORK() производит инициализацию работ более тщательно (советую Вам использовать её), а PREPARE_WORK() используется, если работа была инициализирована, для сокращения времени повторной инициализации.

1.14. Постановка работы в очередь

Работа поставлена в очередь —- она попадает в список и через какое-то время (не мгновенно) будет выполнена.

Инициализировав работу, требуется поставить ее в очередь. Это делает функция:

```
1 bool queue_work(struct workqueue_struct *queue, struct work_struct *work);
```

queue — очередь, в которую мы хотим поставить работу; work — инициализированная структура work_struct.

Также есть

```
1 bool queue_delayed_work(..., unsigned long delay); // ... – те же два параметра
```

delay — время, через которое данная работа может быть поставлена в очередь. Определяет количество jiffes («мгновений»).

queue_work() определена через queue_work_on().

1.15. Завершение работы/очереди работ

Принудительное завершение очереди работ:

```
1 extern void _flush_workqueue(struct worqueue_struct *wq);
```

Принудительно завершить работу и блокировать прочую обработку прежде, чем работа будет закончена:

```
1 extern bool flush_work(struct work_struct *work);
```

Чтобы абсолютно точно отменить выполнение (отменить работу, если она еще не выполнена обработчиком; завершит работу в очереди, либо возникнет блокировка до тех пор, пока не будет завершен обратный вызов (если работа уже выполняется обработчиком)), советуют использовать:

```
1 extern bool cancel_work(...);
```

Если работа отложена, вы можете использовать функции flush_delayed_work() и cancel_delayed_work().

Пример:

```
1  #include <linux/module.h>
2  #include <linux/kernel.h>
3  #include <linux/interrupt.h>
4  #include <linux/slab.h>
5  #include <asm/io.h>
6  #include <linux/stddef.h>
7  #include <linux/workqueue.h>
8  #include <linux/delay.h>
9
10 #include "ascii.h"
11
12 #define IRQ_NUMBER 1
13
14 MODULE_LICENSE("GPL");
15 MODULE_AUTHOR("Karpova␣Ekaterina");
16
```

```
17 typedef struct
18 {
19     struct work_struct work;
20     int code;
21 } my_work_struct_t;
22
23 static struct workqueue_struct *my_wq;
24
25 static my_work_struct_t *work1;
26 static struct work_struct *work2;
27
28 void work1_func(struct work_struct *work)
29 {
30     my_work_struct_t *my_work = (my_work_struct_t *)work;
31     int code = my_work->code;
32
33     printk(KERN_INFO "+: ----------");
34     printk(KERN_INFO "+: work1 began");
35
36     printk(KERN_INFO "+: key code - %d", code);
37     if (code < ASCII_LEN)
38         printk(KERN_INFO "+: key press - %s", ascii[code]);
39     if (code > 128 && code < 128 + ASCII_LEN)
40         printk(KERN_INFO "+: key release - %s", ascii[code - 128]);
41
42     printk(KERN_INFO "+: work1 ended");
43     printk(KERN_INFO "+: ----------");
44 }
45
46 void work2_func(struct work_struct *work)
47 {
48     printk(KERN_INFO "+: ----------");
49     printk(KERN_INFO "+: work2 began");
50     msleep(10);
51     printk(KERN_INFO "+: work2 ended");
52     printk(KERN_INFO "+: ----------");
53 }
54
```

```
55 irqreturn_t my_irq_handler(int irq, void *dev)
56 {
57     int code;
58     printk(KERN_INFO "+: my_irq_handler called\n");
59 
60     if (irq != IRQ_NUMBER)
61     {
62         printk(KERN_INFO "+: irq not handled");
63         return IRQ_NONE;
64     }
65 
66     code = inb(0x60);
67     work1->code = code;
68 
69     queue_work(my_wq, (struct work_struct *)work1);
70     queue_work(my_wq, work2);
71 
72     return IRQ_HANDLED;
73 }
74 
75 static int __init my_init(void)
76 {
77     int rc = request_irq(IRQ_NUMBER, my_irq_handler, IRQF_SHARED,
78                          "work_irq_handler", (void *) my_irq_handler);
79     if (rc) {
80         printk(KERN_ERR "+: cannot register irq handler");
81         return rc;
82     }
83 
84     my_wq = alloc_workqueue("%s", __WQ_LEGACY | WQ_MEM_RECLAIM, 1, "my_wq"
        );
85     if (my_wq == NULL)
86     {
87         printk(KERN_ERR "+: cannot alloc workqueue");
88         return -1;
89     }
90 
91     work1 = kmalloc(sizeof(my_work_struct_t), GFP_KERNEL);
```

```
92      if (work1 == NULL)
93      {
94          printk(KERN_ERR "+: cannot alloc work1");
95          destroy_workqueue(my_wq);
96          return -1;
97      }
98
99      work2 = kmalloc(sizeof(struct work_struct), GFP_KERNEL);
100     if (work2 == NULL)
101     {
102         printk(KERN_ERR "+: cannot alloc work2");
103         destroy_workqueue(my_wq);
104         kfree(work1);
105         return -1;
106     }
107
108     INIT_WORK((struct work_struct *)work1, work1_func);
109     INIT_WORK(work2, work2_func);
110
111     printk(KERN_INFO "+: module loaded");
112
113     return 0;
114 }
115
116 static void __exit my_exit(void)
117 {
118     synchronize_irq(IRQ_NUMBER);
119     free_irq(IRQ_NUMBER, my_irq_handler);
120
121     flush_workqueue(my_wq);
122     destroy_workqueue(my_wq);
123     kfree(work1);
124     kfree(work2);
125
126     printk(KERN_INFO "+: module unloaded");
127 }
128
129 module_init(my_init);
```

```
130 module_exit(my_exit);
```